

Problema

Organizar o catálogo de filmes e séries do IMDb em um formato semelhante ao catálogo de um serviço de *streaming*, distinguindo filmes, séries e episódios, identificando seus gêneros, avaliações e elenco principal. A partir dessas informações, pretendo analisar a distribuição do catálogo e identificar as produções mais bem avaliadas pelos usuários.

Perguntas de negócio

1. Quantos filmes e séries existem no catálogo analisado?
2. Como os gêneros se distribuem entre filmes e séries?
3. Quais são os 10 filmes mais bem avaliados?
4. Quais gêneros predominam entre os filmes mais bem avaliados?
5. Quais são as 10 séries mais bem avaliadas?
6. Quais gêneros predominam entre as séries mais bem avaliadas?

Modelo escolhido foi o Esquema Estrela.

Tabelas:

- `dim_title` — dimensão de títulos (filmes, séries e episódios)
- `dim_genre` — dimensão de gêneros
- `bridge_title_genre` — relacionamento entre títulos e gêneros
- `dim_person` — dimensão de elenco (atores e atrizes)
- `bridge_title_cast` — relacionamento entre títulos e elenco
- `dim_episode` — relacionamento entre episódios e suas respectivas séries
- `fact_ratings` — fato contendo avaliação média e quantidade de votos

Contexto dos dados brutos

Fonte: IMDb Non-Commercial Datasets (<https://developer.imdb.com/non-commercial-datasets/>).

Licença dos dados: Uso pessoal e não comercial, conforme os termos do IMDb Non-Commercial Datasets. Os dados podem ser mantidos em cópia local, mas não podem ser redistribuídos comercialmente.

Carga dos Dados (Etapa 4.2)

A carga dos dados foi implementada no notebook `00_bronze_coleta.py`. Os arquivos do IMDb (`title.basics.tsv.gz`, `title.ratings.tsv.gz`, `title.principals.tsv.gz`, `name.basics.tsv.gz` e `title.episode.tsv.gz`) foram previamente enviados para um Volume do Databricks.

Os dados são então armazenados em tabelas Delta na camada Bronze da arquitetura medalhão, sem alterações no conteúdo original. Durante a ingestão, são adicionados metadados de rastreabilidade (`_ingestion_timestamp` e `_source_file`) para identificar quando e de qual arquivo cada registro foi carregado.

Tabelas criadas na camada Bronze:

- `bronze.title_basics`
- `bronze.title_ratings`
- `bronze.title_principals`

- *bronze.name_basics*
- *bronze.title_episode*

O notebook *00_bronze_coleta.py* e os demais estão **disponíveis** em:

<https://github.com/meduardaae/imdb-data-engineering-mvp/tree/54ad697dfad59cd2906be9192ee9e272aec11dc2/notebooks>

Modelagem e Catálogo de Dados (Etapa 4.3)

A camada Gold foi modelada utilizando um esquema Estrela, com o objetivo de facilitar consultas analíticas e responder às perguntas de negócio relacionadas a filmes, séries, gêneros, elenco e avaliações.

O modelo é composto por dimensões, tabelas de relacionamento (bridge) e uma tabela fato:

1. Dimensões

1.1. *dim_title*: Armazena informações dos títulos presentes no catálogo.

Principais atributos:

- *title_id*
- *title_type*
- *primary_title*
- *original_title*
- *start_year*
- *end_year*
- *runtime_minutes*
- *is_adult*

1.2. *dim_genre*: Armazena os gêneros das produções.

Principais atributos:

- *genre_id*
- *genre_name*

1.3. *dim_person*: Armazena informações do elenco.

Principais atributos:

- *person_id*
- *primary_name*
- *birth_year*

1.4. *dim_episode*: Representa o relacionamento entre episódios e suas respectivas séries.

Principais atributos:

- *episode_title_id*
- *series_title_id*
- *season_number*
- *episode_number*

2. Tabelas de Relacionamento

2.1. *bridge_title_genre*: Relaciona títulos e gêneros, permitindo que uma produção possua múltiplos gêneros.

Campos:

- *title_id*
- *genre_id*

2.2. *bridge_title_cast*: Relaciona títulos e elenco.

Campos:

- *title_id*

- person_id
- characters
- ordering

3. Tabela Fato

3.1. fact_ratings: Armazena as métricas de avaliação do IMDb.

Campos:

- title_id
- average_rating
- num_votes

Como exemplo do catálogo de dados gerado automaticamente pelo Unity Catalog, as Figuras 1 e 2 apresentam respectivamente a estrutura da dimensão de pessoas (dim_person) e da tabela fato de avaliações (fact_ratings).

The screenshot displays the Databricks Unity Catalog interface. On the left, a sidebar contains navigation options like 'New', 'Home', 'Learn', 'Workspace', 'Recents', 'Catalog', 'Jobs & Pipelines', 'Compute', 'Discover', 'Marketplace', 'SQL', 'SQL Editor', 'Queries', 'Dashboards', 'Genie Agents', 'Alerts', 'Query History', 'SQL Warehouses', 'Data Engineering', 'Runs', 'Data Ingestion', 'Visual Data Prep', 'AI/ML', 'Playground', 'Agents', 'AI Gateway', and 'Experiments'. The main panel shows the 'Catalog Explorer' for the 'workspace' and 'gold' schema, listing tables such as 'bridge_title_cast', 'bridge_title_genre', 'dim_episode', 'dim_genre', 'dim_person', 'dim_title', 'fact_ratings', and 'vw_catalogo'. The 'dim_person' table is selected, and its details are shown on the right. The 'Overview' tab is active, displaying a 'Description' section with an 'AI generate' button. Below this is a table of columns with headers: 'Column', 'Type', 'Popular...', 'Comment', 'Tags', and 'Column masking'. The columns listed are 'person_id' (string), 'primary_name' (string), 'birth_year' (int), 'death_year' (int), and 'professions' (array). The 'About this table' section shows the owner as 'meduardaae@gmail.com', the type as 'Managed', the data source as 'Delta', and the popularity as 'High'. The 'Quality' section indicates that data quality monitoring is not enabled for this table, with an 'Enable' button. The 'Policies' section is also visible at the bottom.

Column	Type	Popular...	Comment	Tags	Column masking
person_id	string	---			
primary_name	string	...			
birth_year	int	---			
death_year	int	---			
> professions: {"items": "string"}	array	---			

Figura 1: Catálogo de dados da dimensão dim_person.




Figura 2: Catálogo de dados da tabela fato `fact_ratings`.

Script de referência: `02_gold_modelagem.py`

Pipeline de Dados (Etapa 4.4)

O processo de ETL foi organizado utilizando a arquitetura medalhão (Bronze → Silver → Gold) e distribuído em 3 notebooks, permitindo manutenção, reexecução e depuração independentes em cada etapa.

Organização do Pipeline

Ordem	Notebook	Camada	Responsabilidade
1	<code>00_bronze_coleta.py</code>	Bronze	Leitura dos arquivos brutos do IMDb armazenados em um Volume do Databricks e carga para tabelas Delta
2	<code>01_silver_limpeza.py</code>	Silver	Limpeza, tipagem, deduplicação, padronização e tratamento dos dados
3	<code>02_gold_modelagem.py</code>	Gold	Construção do modelo dimensional (Esquema Estrela)
4	<code>03_qualidade_dados.py</code>	Qualidade	Avaliação da completude, unicidade, consistência e validade dos dados
5	<code>04_analise.py</code>	Análise	Resposta às perguntas de negócio e geração de visualizações

- **Extração**

A extração foi realizada a partir dos arquivos obtidos no IMDb apresentados no tópico de Carga de Dados. Eles foram lidos com Apache Spark e gravados na camada Bronze sem alterações de conteúdo.

Script de referência: 00_bronze_coleta.py

- **Transformação**

As transformações foram implementadas no notebook 01_silver_limpeza.py, e os principais tratamentos realizados foram a:

- remoção de registros duplicados;
- conversão de tipos de dados;
- tratamento de valores inválidos;
- padronização de tipos de produção;
- transformação de gêneros em listas;
- filtragem de títulos avaliados;
- construção das estruturas de elenco;
- tratamento da relação entre séries e episódios.

Script de referência: 01_silver_limpeza.py

- **Load (Carga)**

Após as transformações, os dados foram persistidos em tabelas Delta nas camadas Silver e Gold.

Tabelas Silver:

- title_basics
- title_ratings
- title_rated
- title_principals
- cast_people
- title_cast
- title_episode

Tabelas Gold:

- dim_title
- dim_genre
- bridge_title_genre
- dim_person
- bridge_title_cast
- dim_episode

- fact_ratings
- vw_catalogo

Scripts: 01_silver_limpeza.py e 02_gold_modelagem.py.

A persistência das estruturas analíticas criadas durante o processo de ETL pode ser observada na Figura 3, que apresenta as tabelas da camada Gold registradas no Databricks.




Figura 3: Estruturas da camada Gold geradas pelo pipeline de ETL e armazenadas no Unity Catalog do Databricks.

Qualidade de Dados (Etapa 4.5)

A qualidade dos dados foi avaliada no notebook 03_qualidade_dados.py, considerando critérios de completude, unicidade, validade, consistência e presença de outliers.

Problemas Identificados

- Registros duplicados

Foi identificada a possibilidade de existência de registros duplicados nas tabelas de origem do IMDb. Essas duplicidades foram removidas utilizando as chaves naturais das tabelas.

Exemplo:

```
.dropDuplicates(
["tconst", "nconst", "ordering", "category"]
)
```

- Tipos de dados incorretos

Os arquivos do IMDb são carregados originalmente como texto, incluindo colunas numéricas. Foram observados problemas como: ano de lançamento, duração, número de votos e notas armazenados como string. Para corrigi-los foi aplicada a conversão explícita de tipos:

startYear → *int*

endYear → *int*

runtimeMinutes → *int*

numVotes → *int*

averageRating → *double*

- **Registros malformados em runtimeMinutes**

Durante a análise de qualidade foram encontrados registros em que valores categóricos apareciam indevidamente na coluna de duração, que impediam a conversão direta para número inteiro. Para corrigi-los, foi aplicada a conversão direta, os valores inválidos foram convertidos para nulos sem interromper o processamento.

Os exemplos observados foram:

- Plain Text
- Reality-TV
- Talk-Show
- News,Talk-Show

- **Títulos sem avaliações**

A análise do projeto depende diretamente da existência de avaliações. Desta forma, foram mantidos apenas títulos que possuem registros válidos na tabela *title_ratings*. Essa decisão reduziu significativamente o volume de dados e manteve apenas produções relevantes para as análises.

Análise de Dados (Etapa 4.5)

A etapa de análise foi implementada no notebook *04_analise.py* utilizando as tabelas da camada Gold construídas no modelo dimensional. O objetivo foi responder às perguntas de negócio definidas no início do projeto e explorar o catálogo do IMDb sob a perspectiva de filmes, séries, gêneros e avaliações.

- **Pergunta 1**

Foi realizada uma contagem dos registros da dimensão `'dim_title'`, considerando os tipos de produção classificados como Filme e Série.

Resultado:

- Total de filmes: 406.415
- Total de séries: 140.646

- **Pergunta 2**

A distribuição dos gêneros foi obtida por meio da integração entre as tabelas:


- `'dim_title'`

- `'bridge_title_genre'`
- `'dim_genre'`

Foram gerados gráficos mostrando a frequência dos gêneros para filmes e séries.

Principais observações:

- Drama aparece entre os gêneros mais frequentes.
- Outros gêneros relevantes incluem Comedy, Crime, Action e Documentary.




• Pergunta 3

Foi criado um ranking usando a nota média (`'average_rating'`) presente na tabela `'fact_ratings'`. Para aumentar a confiabilidade dos resultados, foram considerados apenas títulos com pelo menos 10.000 votos.

Principais observações:

- Os filmes mais bem avaliados apresentam notas muito próximas entre si.
- A maioria pertence aos gêneros Drama e Crime.




• Pergunta 4

Foram analisados os gêneros presentes nos 10 filmes com maior avaliação.

Principais observações:

- Drama foi o gênero mais frequente.
- Crime e Mystery também apresentaram forte presença.



• Pergunta 5

Foi criado um ranking semelhante ao dos filmes, utilizando nota média e pelo menos 10.000 votos.

Principais observações:

- As séries mais bem avaliadas possuem grande quantidade de avaliações.
- As notas observadas indicam elevado reconhecimento pelo público.

top_series: pandas.core.frame.DataFrame = [primary_title: object, start_year: int32 ... 3 more fields]

Table

+


	primary_title	start_year	generos	average_rating
1	Breaking Bad	2008	Crime, Thriller, Drama	9.5
2	Steel Ball Run: JoJo's Bizarre Adventure	2026	Adventure, Action, Animation	9.5
3	Band of Brothers	2001	History, Drama, Action	9.4
4	Planet Earth	2006	Family, Documentary	9.4
5	Planet Earth II	2016	Family, Documentary	9.4
6	Chernobyl	2019	History, Thriller, Drama	9.3
7	The Wire	2002	Crime, Thriller, Drama	9.3
8	Blue Planet II	2017	Family, Documentary	9.3
9	Cosmos	1980	Documentary	9.3
10	Avatar: The Last Airbender	2005	Adventure, Action, Animation	9.3

10 rows

5.134s runtime

Refreshed 5m ago

- Pergunta 6
- A análise dos gêneros presentes entre as séries mais bem avaliadas indicou forte presença de:
- Drama
 - Documentary
 - Action



Conclusão

A análise mostrou que o catálogo do IMDb possui uma quantidade significativamente maior de filmes do que séries. Os gêneros Drama, Crime e Mystery aparecem com frequência tanto no catálogo geral quanto entre as produções mais bem avaliadas. Além disso, a utilização de um critério mínimo de 10.000 votos permitiu reduzir o efeito de avaliações pouco representativas e aumentar a confiabilidade dos rankings apresentados.

Autoavaliação

O objetivo principal deste projeto foi construir um pipeline completo de Engenharia de Dados para organizar informações do IMDb em um catálogo semelhante ao de serviços de streaming. Considero que os objetivos definidos no início do trabalho foram atingidos com sucesso, uma vez que foi possível implementar todas as etapas do processo, desde a ingestão dos dados até a geração de análises capazes de responder às perguntas de negócio propostas.

A principal dificuldade encontrada esteve relacionada ao grande volume de dados. Algumas tabelas possuem dezenas de milhões de registros, o que exigiu a definição de estratégias para reduzir o volume processado sem comprometer os objetivos do projeto. Outra dificuldade foi lidar com registros inconsistentes e campos com tipos de dados inadequados, exigindo a aplicação de validações, conversões e tratamentos de qualidade de dados antes da modelagem.

Também foi desafiador compreender o relacionamento entre os diferentes conjuntos de dados do IMDb e construir uma modelagem dimensional adequada para representar títulos, gêneros, elenco, episódios e avaliações. Esse processo exigiu diversas iterações até chegar a uma estrutura consistente e alinhada às perguntas de negócio.

Por fim, como trabalhos futuros, seria interessante enriquecer o catálogo com informações adicionais não presentes nos datasets utilizados, como sinopses, pôsteres, idiomas, países de origem e empresas de produção.